

# 最优化方法

哈尔滨工业大学  
数学学院

杨 畅

# 第四章

## 最优化搜索算法的结构 与 一维搜索

## 4.1常用的搜索算法结构

### 1.收敛性概念：考虑 $(fs)$

设迭代算法产生点列  $\{x^{(k)}\} \subseteq S$ 。

(1) 理想的收敛性：设  $x^* \in S$  是 g.opt.

1° 当  $x^* \in \{x^{(k)}\}$

2°  $x^{(k)} \neq x^*$ ,  $\forall k$ , 但满足:  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$

时, 称算法收敛到最优解  $x^*$ 。

概念：由于非线性规划问题的复杂性，实用中建立下列收敛性

**(2) 实用收敛性：定义解集**

$$S^* = \{ \mathbf{x} \mid \mathbf{x} \text{ 具有某种性质} \}$$

例如：  $S^* = \{ \mathbf{x} \mid \mathbf{x} \text{—g.opt.} \}$

$$S^* = \{ \mathbf{x} \mid \mathbf{x} \text{—l.opt.} \}$$

$$S^* = \{ \mathbf{x} \mid \nabla f(\mathbf{x}) = \mathbf{0} \}$$

$$S^* = \{ \mathbf{x} \mid f(\mathbf{x}) \leq \beta \}$$

( $\beta$ 为给定的实数，称为阈值)

▲ **收敛性**：设解集  $S^* \neq \emptyset$ ， $\{\mathbf{x}^{(k)}\}$  为算法产生的点列。  
下列情况之一成立时，称算法收敛：

1°  $\exists \mathbf{x}^{(k)} \in S^*$ ;

2°  $\mathbf{x}^{(k)} \notin S^*$ ,  $\forall k$ , 但  $\{\mathbf{x}^{(k)}\}$  任意极限点  $\in S^*$ 。

▲ **全局收敛**：对任意初始点  $\mathbf{x}^{(1)}$ , 算法均收敛。

**局部收敛**：当  $\mathbf{x}^{(1)}$  充分接近解  $\mathbf{x}^*$  时，算法才收敛。

## 2.收敛速度

设算法产生点列 $\{x^{(k)}\}$ ,收敛到解 $x^*$ ,且 $x^{(k)} \neq x^*$ ,  $\forall k$ ,

(1) 线性收敛:  $\frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} < 1$ , 当 $k$ 充分大时成立。

(2) 超线性收敛:  $\lim_{k \rightarrow \infty} \frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0$

(3) 二阶收敛:  $\exists \alpha > 0$ , 使得当 $k$ 充分大时, 有

$$\frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|^2} \leq \alpha$$

**定理** 设算法点列 $\{x^{(k)}\}$ 超线性收敛于 $x^*$ , 且 $x^{(k)} \neq x^*$ ,  $\forall k$ , 那么

$$\lim_{k \rightarrow \infty} \frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k)} - x^*\|} = 1$$

证明只需注意

$$\begin{aligned} | \|x^{(k+1)} - x^*\| - \|x^{(k)} - x^*\| | &\leq \|x^{(k+1)} - x^{(k)}\| \\ &\leq \|x^{(k+1)} - x^*\| + \|x^{(k)} - x^*\| \end{aligned}$$

同除以 $\|x^{(k)} - x^*\|$ , 并令 $k \rightarrow \infty$ , 利用超线性收敛定义可得结果。

### 3. 线性搜索算法

设已得到迭代点  $\mathbf{x}^{(k)}$  :

( 1 ) 确定搜索方向  $\mathbf{d}^{(k)}$

( 2 ) 求  $\lambda_k$  , 使  $\mathbf{f}(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min(\mathbf{f}(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) \mid \lambda \in R_k)$  。 其中  $R_k$  是针对问题得到的限制集合。

( 3 ) 令  $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$

➤ 如果  $R_k = R$  , 那么在一定条件下线性搜索的结果就当有

$$\frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})}{d\lambda} \Big|_{\lambda = \lambda_k} = 0$$

即  $\nabla f^T(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) \mathbf{d}^{(k)} = 0$



## 4.二次终结性

➤ 一个算法用于解正定二次函数 ( $f(x)=1/2x^T Ax-c^T x$ ,  $A$ 为对称正定) 的无约束极小时, 有限步迭代可达最优解, 则称该算法具有二次终结性。

➤ 二次终结性=共轭方向+精确一维搜索。



➤ 共轭方向

▪ **定义** 设  $A_{n \times n}$  对称正定,  $d^{(1)}, d^{(2)} \in R^n$ ,  
 $d^{(1)} \neq 0$ ,  $d^{(2)} \neq 0$ , 满足  $d^{(1)T} A d^{(2)} = 0$ , 称  $d^{(1)}, d^{(2)}$  关于矩阵  $A$  共轭。

▪ 共轭向量组:  $d^{(1)}, d^{(2)}, \dots, d^{(m)} \in R^n$  均非零, 满足

$$d^{(i)T} A d^{(j)} = 0 (i \neq j)。$$

▪ 当  $A=E$ (单位矩阵)时,  $d^{(1)T} A d^{(2)} = d^{(1)T} d^{(2)} = 0$ , 即正交关系。



· 当 $d^{(1)}, d^{(2)}, \dots, d^{(m)}$  关于正定矩阵 $A$ 两两共轭时,  $d^{(1)}, d^{(2)}, \dots, d^{(m)}$  线性无关。

证明. 设 $d = \alpha_1 d^{(1)} + \alpha_2 d^{(2)} + \dots + \alpha_m d^{(m)} = 0$ ,  $\forall j=1, 2, \dots, m$ ,  
 $d^{(j)\top} A d = \alpha_j d^{(j)\top} A d^{(j)} = 0$

因为  $d^{(j)\top} A d^{(j)} > 0$ , 故  $\alpha_j = 0$ , 即线性无关。

**定理** : 设 $d^{(1)}, d^{(2)}, \dots, d^{(m)}$ ,  $m < n$ , 非零、关于 $A$ 两两共轭。设 $x^{(1)} \in R^n$ ,

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}, k=1, \dots, m$$

$\lambda_k$ 为 $\lim_{\lambda} f(x^{(k)} + \lambda d^{(k)})$ 的最优解。

那么 $x^{(m+1)}$ 为 $\begin{cases} \min f(x) \\ \text{s.t. } x \in V \end{cases}$ 的最优解, 其中

$$V = \{x | x = x^{(1)} + \sum_{i=1}^m \mu_i d^{(i)}, \mu_i \in R, i = 1, \dots, m\}.$$

**注** : 超线性收敛和二次终结性常用来讨论算法的优点。

## 5. 下降算法模型

考虑 (fs) 
$$\begin{cases} \text{Min } f(x) \\ \text{s.t. } x \in S \end{cases}$$

常用一种线性搜索的方式来求解：迭代中从一点出发沿下降可行方向找一个新的、性质有改善的点。

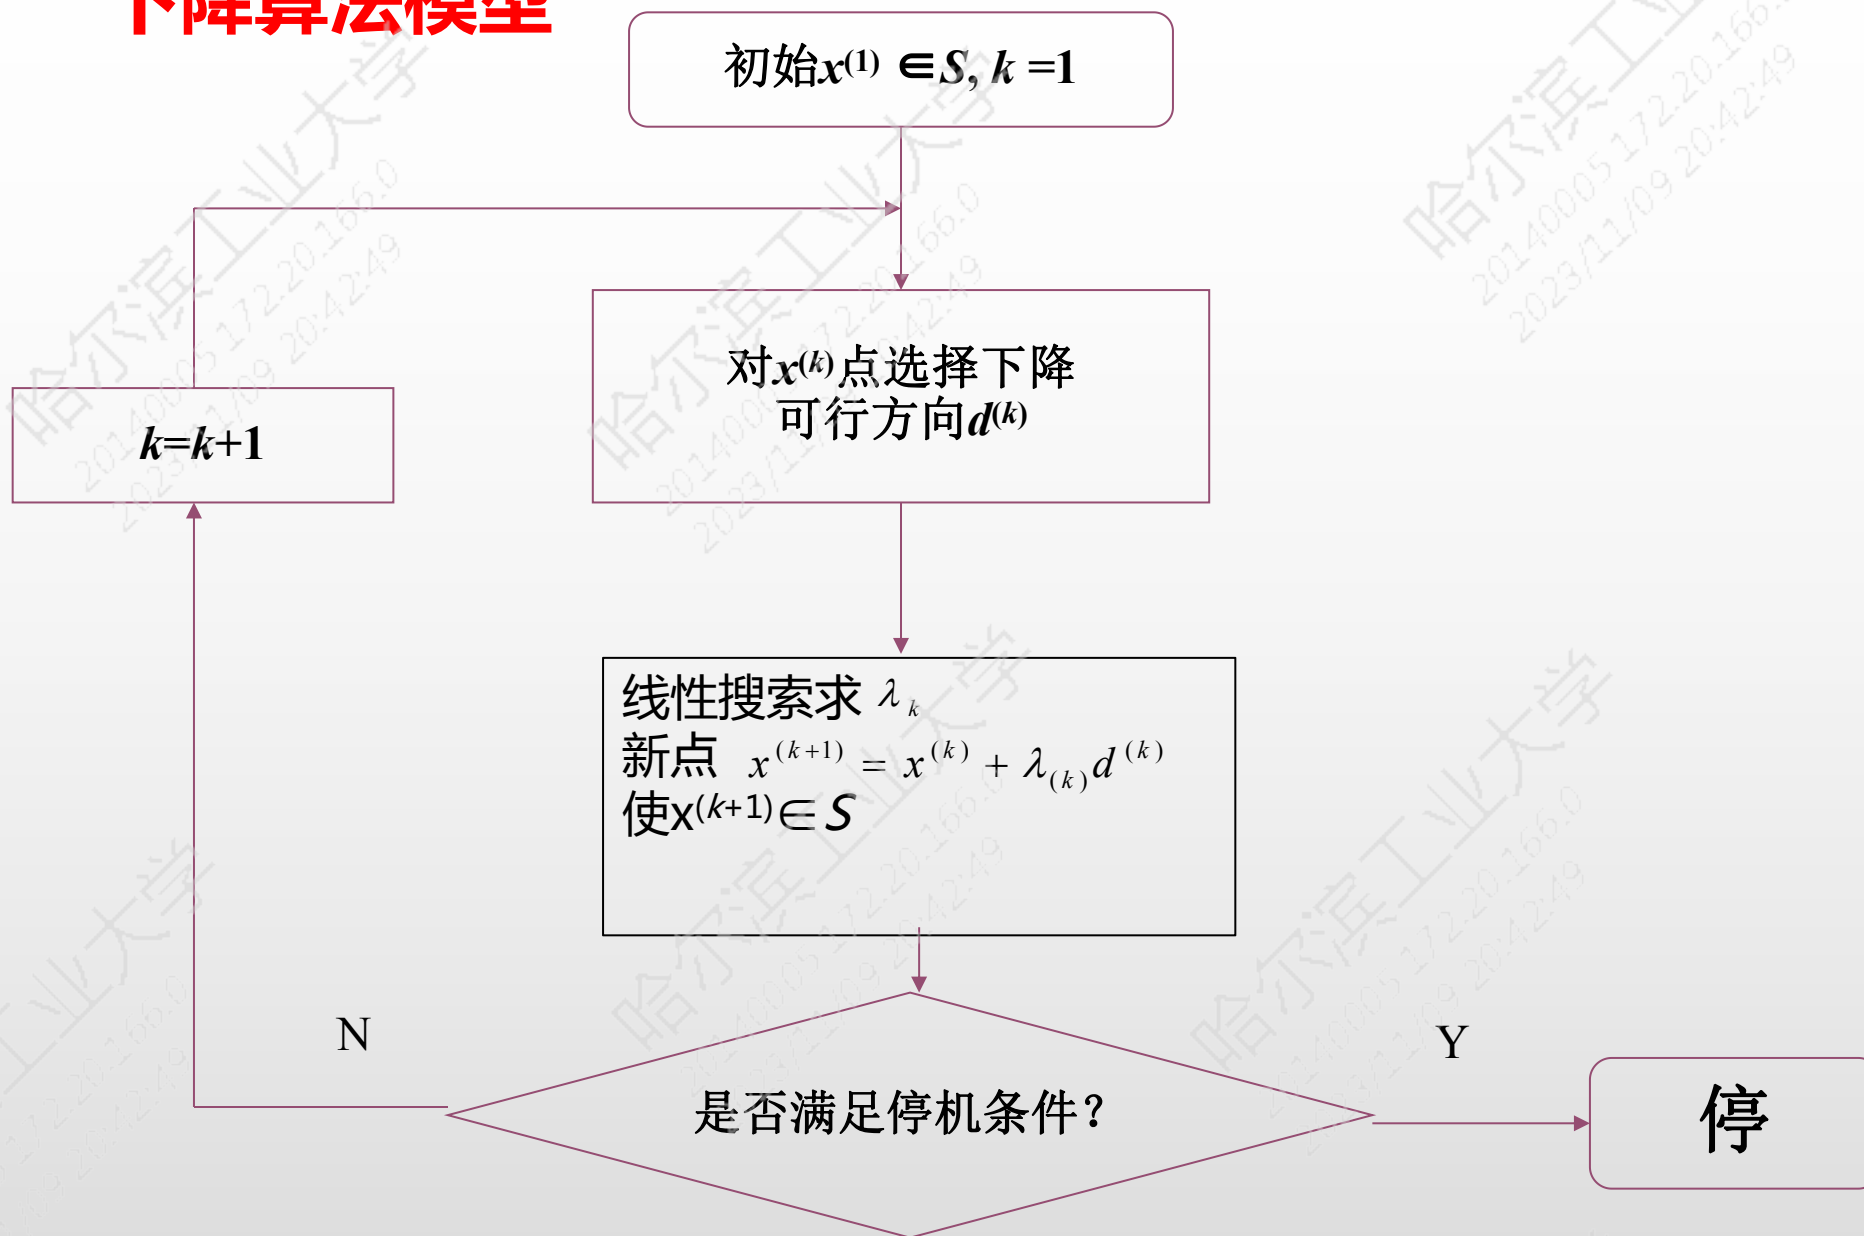
### ➤ 下降方向

设  $\bar{x} \in S$ ,  $d \in \mathbb{R}^n, d \neq 0$ , 若存在  $\delta > 0$ , 使  $f(\bar{x} + \lambda d) < f(\bar{x}), \forall \lambda \in (0, \delta)$ , 称  $d$  为在  $\bar{x}$  点的下降方向。

➤ 可行方向：设  $\bar{x} \in S$ ,  $d \in \mathbb{R}^n, d \neq 0$ , 若存在  $\delta > 0$ , 使  $\bar{x} + \lambda d \in S, \forall \lambda \in (0, \delta)$ , 称  $d$  为  $\bar{x}$  点的可行方向。

同时满足上述两个性质的方向称为下降可行方向。

# 下降算法模型



## 4.2 一维搜索

一元函数求极小值及线性搜索均为一维搜索。常用于求：

$$\text{Min } f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) = \varphi(\lambda)$$

$$\text{s.t. } \lambda \in S$$

$S$ 有3种情况  $(-\infty, +\infty)$  或  $(0, +\infty)$  或  $[a, b]$

**1. 缩小区间的精确一维搜索：**考虑问题( $P$ )

$$\text{Min } \varphi(\lambda)$$

$$\text{s.t. } \lambda \in [\alpha, \beta]$$

其中  $\varphi(\lambda): \mathbb{R} \rightarrow \mathbb{R}$

(1) 不确定区间及单峰函数

➤ 不确定区间： $[\alpha, \beta]$ 含 $\varphi(\lambda)$ 的最小点，但不知其位置。


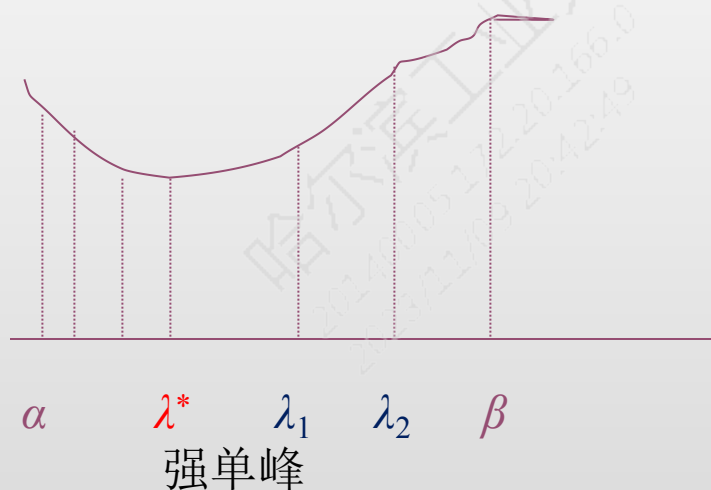
**定义** 设  $\varphi : [\alpha, \beta] \rightarrow \mathbf{R}$  ,  $\exists \lambda^* \in [\alpha, \beta]$  是  $\varphi$  在  $[\alpha, \beta]$  上的最小点 , 若对任意  $\lambda_1, \lambda_2$  ,  $\alpha \leq \lambda_1 < \lambda_2 \leq \beta$  满足 :

1° 若  $\lambda_2 \leq \lambda^*$  , 则  $\varphi(\lambda_1) > \varphi(\lambda_2)$  ;

2° 若  $\lambda^* \leq \lambda_1$  , 则  $\varphi(\lambda_1) < \varphi(\lambda_2)$  .

则称  $\varphi(\lambda)$  在  $[\alpha, \beta]$  上强单峰。


若只有当  $\varphi(\lambda_1) \neq \varphi(\lambda^*)$  ,  $\varphi(\lambda_2) \neq \varphi(\lambda^*)$  时 , 上述 1°, 2° 中的式子才成立 , 则称  $\varphi(\lambda)$  在  $[\alpha, \beta]$  上单峰。



**定理** 设  $\Phi : \mathbb{R} \rightarrow \mathbb{R}$  在  $[\alpha, \beta]$  上单峰,  $\alpha \leq \lambda < \mu \leq \beta$ 。那么

1° 若  $\Phi(\lambda) > \Phi(\mu)$ , 则  $\Phi(\rho) \geq \Phi(\mu)$ ,  $\forall \rho \in [\alpha, \lambda]$ , 如左下图所示;

2° 若  $\Phi(\lambda) < \Phi(\mu)$ , 则  $\Phi(\rho) \geq \Phi(\lambda)$ ,  $\forall \rho \in [\mu, \beta]$ , 如右下图所示。



**证明.** 1°反证法: 设  $\lambda^* \in [\alpha, \beta]$  为最小点, 假设  $\gamma \in [\alpha, \lambda]$  及  $\gamma < \lambda < \lambda^*$ , 使  $\Phi(\gamma) < \Phi(\mu) < \Phi(\lambda)$ 。

若  $\lambda^* \in [\lambda, \beta]$ , 由定义  $\Phi(\gamma) > \Phi(\lambda)$ , 矛盾 (假设);

若  $\lambda^* \in [\alpha, \lambda)$ , 由定义及  $\mu > \lambda \geq \lambda^*$ ,  $\Phi(\mu) > \Phi(\lambda)$ , 矛盾 (条件); 于是结论成立。

2°的证明类似 (略)。

**启示:** 通过上述定理, 选两点  $\lambda$  和  $\mu$ , 比较  $\Phi(\lambda)$  与  $\Phi(\mu)$ , 可去掉  $[\alpha, \lambda]$  或者  $[\mu, \beta]$ 。

## (2)进退法求初始不确定区间

找三点使两端点的函数值大于中间点的函数值。

**思路：**任取 $\lambda_0$ ，步长 $\delta > 0$ ，取 $\lambda_1 = \lambda_0 + \delta$ ，

1°若 $\phi(\lambda_0) < \phi(\lambda_1)$ ，令 $\delta = 2\delta$ （步长加倍）， $\lambda_2 = \lambda_0 - \delta$ ，

若 $\phi(\lambda_2) < \phi(\lambda_0)$ ，则令 $\lambda_1 = \lambda_0$ ， $\lambda_0 = \lambda_2$ ，重复 1°

若 $\phi(\lambda_2) > \phi(\lambda_0)$ ，则停， $\alpha = \lambda_2$ ， $\beta = \lambda_1$  (图1)

2°若 $\phi(\lambda_0) > \phi(\lambda_1)$ ，令 $\delta = 2\delta$ ， $\lambda_2 = \lambda_1 + \delta$ ，

若 $\phi(\lambda_2) < \phi(\lambda_1)$ ，则令 $\lambda_0 = \lambda_1$ ， $\lambda_1 = \lambda_2$ ，重复 2°

若 $\phi(\lambda_2) > \phi(\lambda_1)$ ，则停， $\alpha = \lambda_0$ ， $\beta = \lambda_2$  (图2)




图1




图2

**注：**1°  $\delta$  选择要适当（太大含多个单峰区间，太小迭代次数增加）；

2°  $\phi(\lambda)$  单调时无结果（加迭代次数限制）；





### (3) 中点法

设  $\Phi(\lambda)$  在  $[\alpha, \beta]$  上可微，且当导数为零时是解。取  $\lambda = (\alpha + \beta) / 2$ ，那么

$\Phi'(\lambda) = 0$  时， $\lambda$  为最小点， $\lambda = \lambda^*$ ；

$\Phi'(\lambda) > 0$  时， $\lambda$  在上升段， $\lambda^* < \lambda$ ，去掉  $[\lambda, \beta]$ ；(左下图)

$\Phi'(\lambda) < 0$  时， $\lambda$  在下降段， $\lambda^* > \lambda$ ，去掉  $[\alpha, \lambda]$ 。(右下图)



#### (4) 黄金分割法 (0.618 法)

考虑条件：

1° 对称： $\lambda - \alpha = \beta - \mu$


①

(使“坏”的情况去掉，区间长度不小于“好”的情况)

2° 保持缩减比  $t = (\text{保留的区间长度} / \text{原区间长度})$  不变。

(使每次保留下来的节点， $\lambda$  或  $\mu$ ，在下一次的比较中成为一个相应比例位置的节点)。

推导缩减比  $t$ ：如图设第一次保留  $[\alpha, \mu]$  (去掉  $[\mu, \beta]$ )，那么第二次保留的长度为  $[\alpha, \lambda]$ ，则



$$t = \frac{\mu - \alpha}{\beta - \alpha} = \frac{\lambda - \alpha}{\mu - \alpha}$$


②

不妨设  $\beta - \alpha = 1$  , 则  $\mu - \alpha = t$  ,  $\lambda - \alpha = 1 - t$ 。于是由式②得

$$t/1 = (1-t)/t$$

整理得 :  $t^2 + t - 1 = 0$

故  $t \approx 0.618$


$$t = \frac{-1 \pm \sqrt{5}}{2} (\text{舍去负值})$$

**注 :** 整理式② :  $\mu = \alpha + t(\beta - \alpha)$

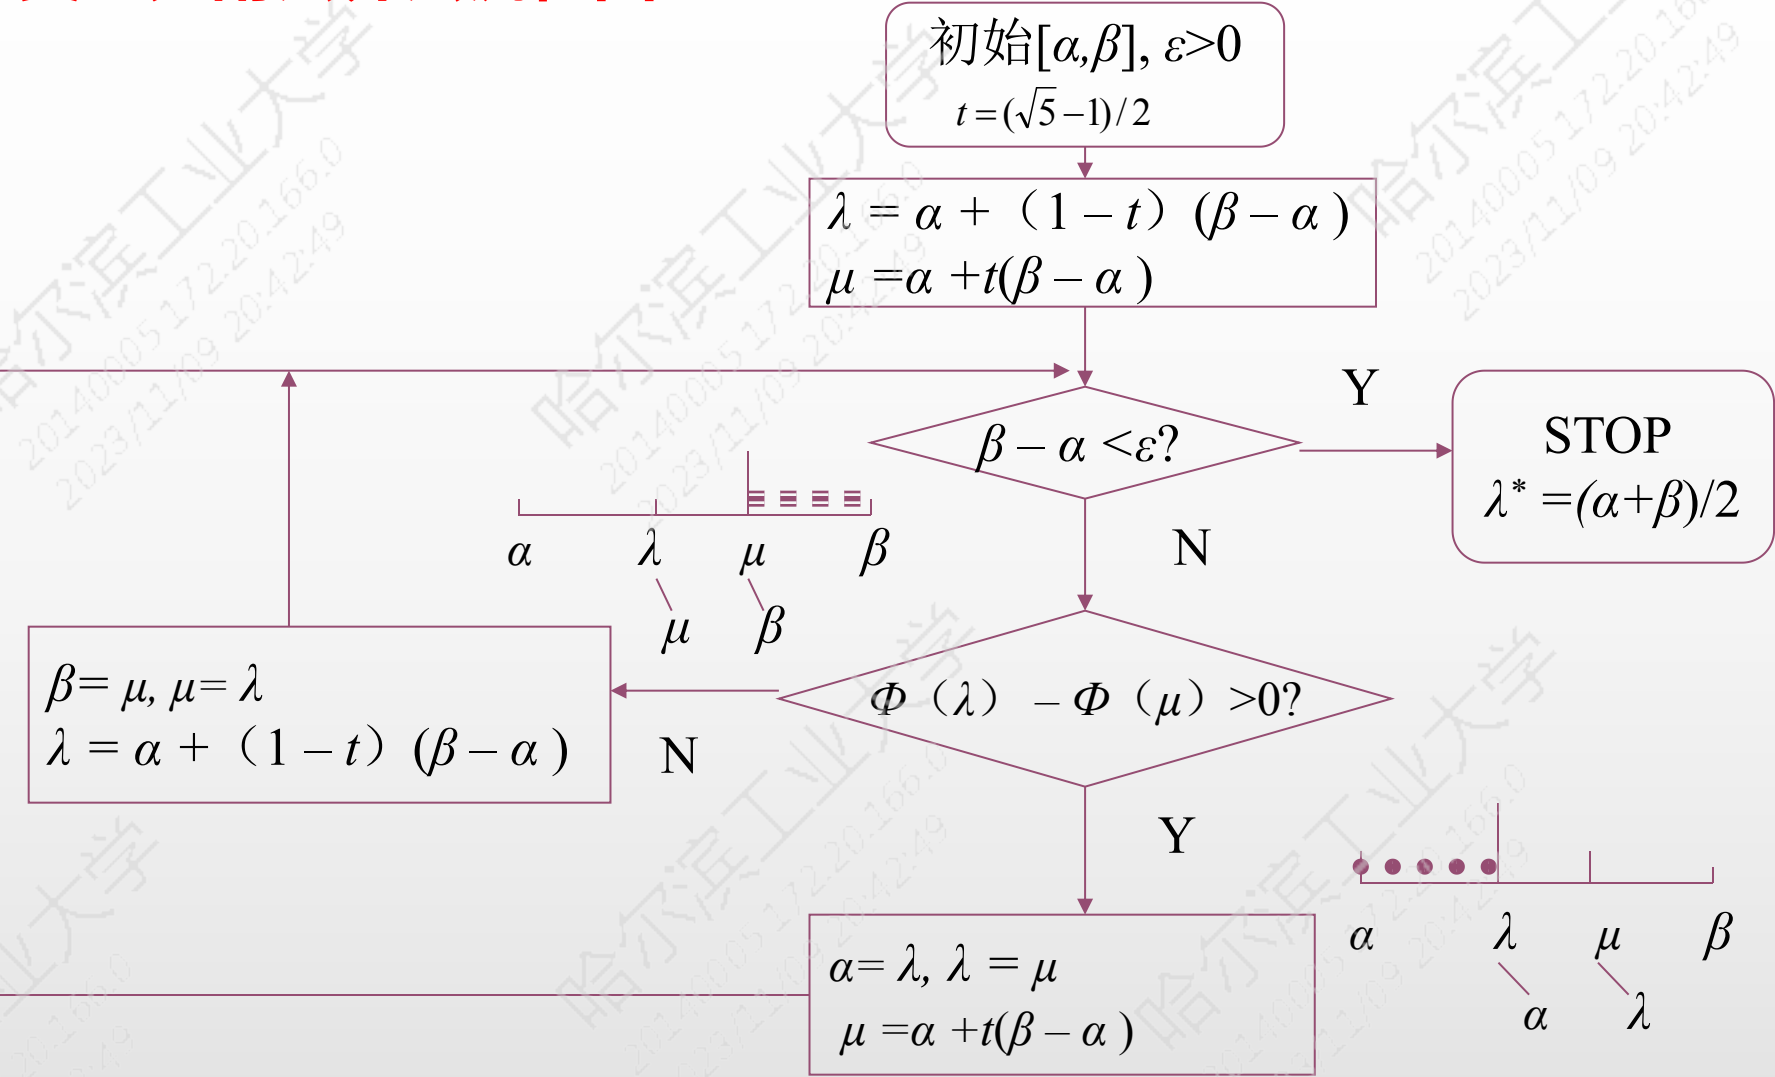
$$\lambda = \alpha + t(\mu - \alpha) = \alpha + t^2(\beta - \alpha)$$

由于  $t^2 = 1 - t$  , 故有

$$\mu = \alpha + t(\beta - \alpha)$$

$$\lambda = \alpha + (1 - t)(\beta - \alpha)$$

黄金分割法算法流程图：



## 2. 牛顿法 (Newton) 和插值法

### (1) 牛顿法

对  $\phi$  在  $\lambda_k$  点展开：

$$\phi(\lambda) = \phi(\lambda_k) + \phi'(\lambda_k)(\lambda - \lambda_k) + (1/2) \phi''(\lambda_k)(\lambda - \lambda_k)^2 + o(\lambda - \lambda_k)^2$$

取二次式 (略去高阶项)：

$$q_k(\lambda) = \phi(\lambda_k) + \phi'(\lambda_k)(\lambda - \lambda_k) + (1/2) \phi''(\lambda_k)(\lambda - \lambda_k)^2$$

用  $q_k(\lambda)$  作为  $\phi(\lambda)$  的近似，当  $\phi''(\lambda_k) > 0$  时  $q_k(\lambda)$  为凸函数，其驻点为极小点：

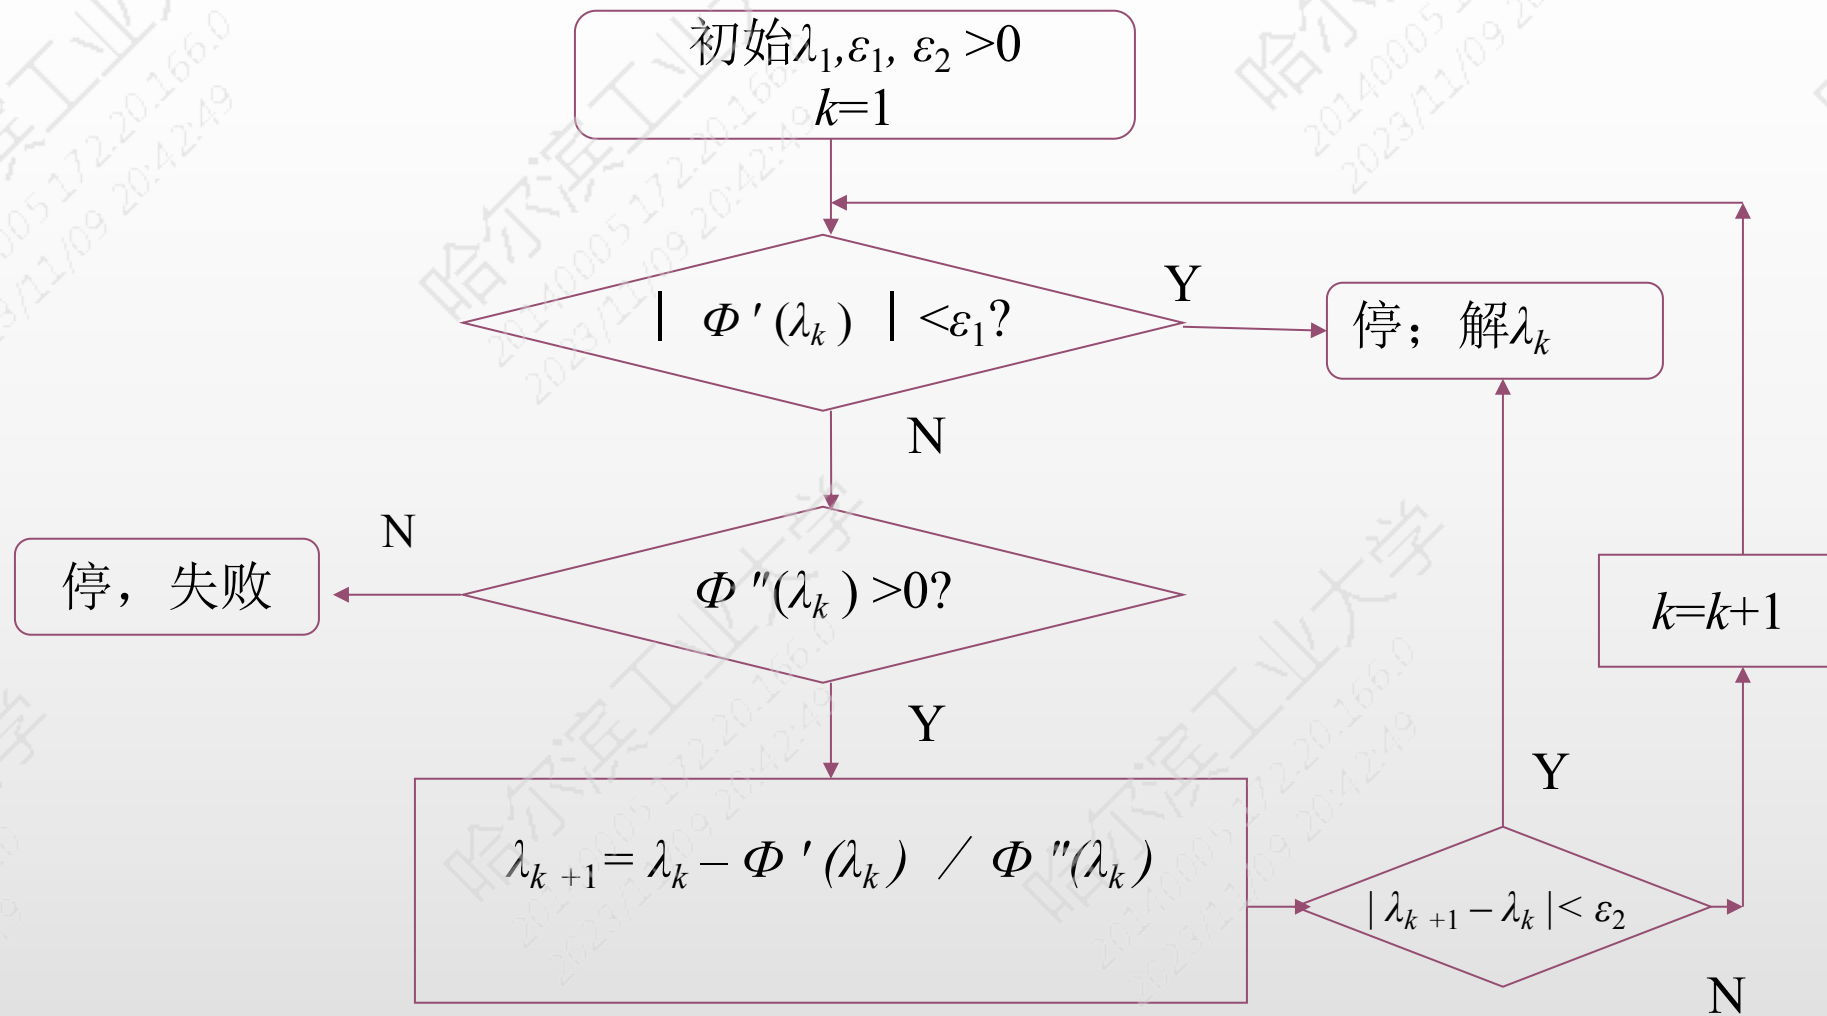
$$q'_k(\lambda) = \phi'(\lambda_k) + \phi''(\lambda_k)(\lambda - \lambda_k) = 0$$

令  $\lambda_{k+1} = \lambda = \lambda_k - \phi'(\lambda_k) / \phi''(\lambda_k)$  为新的迭代点。

以上过程即牛顿法。

**特点：**二阶、局部收敛。

## 牛顿法算法框图：



**例. 求**  $\text{Min } \phi(\lambda) = \int_0^{\lambda} \arctan(t) dt$

**解**  $\phi'(\lambda) = \arctan \lambda$  ,  $\phi''(\lambda) = 1 / (1 + \lambda^2)$

**迭代公式：**  $\lambda_{k+1} = \lambda_k - (1 + \lambda_k^2) \arctan \lambda_k$

**取** $\lambda_1 = 1$  , **计算结果：**

$k$	$\lambda_k$	$\phi'(\lambda_k)$	$1 / \phi''(\lambda_k)$
1	1	0.7854	2
2	- 0.5708	- 0.5187	1.3258
3	0.1169	- 0.1164	1.0137
4	- 0.001095	- 0.001095	

$\lambda_4 \approx \lambda^* = 0$

**取** $\lambda_1 = 2$  , **计算结果如下：**

$k$	$\lambda_k$	$\phi'(\lambda_k)$	$1 / \phi''(\lambda_k)$
1	2	1.1071	5
2	- 3.5357	- 1.2952	13.50
3	13.95	不收敛	

## (2) 插值法

用 $\Phi(\lambda)$ 在2或3个点的函数值或导数值，构造2次或3次多项式作为 $\Phi(\lambda)$ 的近似值，以这个多项式的极小点为新的迭代点。

3点2次，2点2次，4点3次，3点3次，2点3次等

下面以3点2次为例：

取 $\lambda_1, \lambda_2, \lambda_3$ ，求出 $\Phi(\lambda_1), \Phi(\lambda_2), \Phi(\lambda_3)$

设二次插值多项式： $a\lambda^2 + b\lambda + c = \Phi(\lambda)$

$$a\lambda_1^2 + b\lambda_1 + c = \Phi(\lambda_1)$$

$$a\lambda_2^2 + b\lambda_2 + c = \Phi(\lambda_2)$$

$$a\lambda_3^2 + b\lambda_3 + c = \Phi(\lambda_3)$$

解得

$$a = - \frac{(\lambda_1 - \lambda_2)\Phi(\lambda_3) + (\lambda_2 - \lambda_3)\Phi(\lambda_1) + (\lambda_3 - \lambda_1)\Phi(\lambda_2)}{(\lambda_1 - \lambda_2)(\lambda_2 - \lambda_3)(\lambda_3 - \lambda_1)}$$

$$b = \frac{(\lambda_1^2 - \lambda_2^2)\Phi(\lambda_3) + (\lambda_2^2 - \lambda_3^2)\Phi(\lambda_1) + (\lambda_3^2 - \lambda_1^2)\Phi(\lambda_2)}{(\lambda_1 - \lambda_2)(\lambda_2 - \lambda_3)(\lambda_3 - \lambda_1)}$$

$$\bar{\lambda} = - \frac{b}{2a}$$



### 3. 不精确一维搜索： $\text{Min } f(\mathbf{x})$

考虑从  $\mathbf{x}^{(k)}$  点出发，沿方向  $\mathbf{d}^{(k)}$  寻找新迭代点： $\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$

要求：1°  $f(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) < f(\mathbf{x}^{(k)})$ ;

2°  $\lambda_k > 0$  不能太小。

每一步不要求达到精确最小，因此一维搜索速度更快。虽然步数增加，则整体收敛速度更快。

一个实用方法：为了方便，省去上标：

设  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 。在  $\mathbf{x}$  取方向  $\mathbf{d}$ ，有  $\nabla f^T(\mathbf{x})\mathbf{d} < 0$ （即  $\mathbf{d}$  为下降方向）

求  $\lambda$  使


$$1^\circ f(\mathbf{x} + \lambda \mathbf{d}) \leq f(\mathbf{x}) + \alpha \lambda \nabla f^T(\mathbf{x})\mathbf{d}$$

$$2^\circ \nabla f^T(\mathbf{x} + \lambda \mathbf{d})\mathbf{d} \geq \beta \nabla f^T(\mathbf{x})\mathbf{d}$$


其中  $\alpha \in (0, 1/2)$ ，

$\beta \in (\alpha, 1)$  为取定参数。

实际中常取  $\alpha=0.1$ ， $\beta=0.7$  附近。



## 不精确一维搜索流程图



要提高精确度可把2° 改为:

$$2^{\circ} \quad |\nabla f^T(x + \lambda d) d| \leq -\gamma \nabla f^T(x) d$$

当 $\gamma=0$ 时变成精确一维搜索。

此方法一般经几次迭代即可得到满意的 $\lambda_k$ 。

