



# 最优化方法

哈尔滨工业大学  
数学学院

杨 畅



# 第五章

## 无约束最优化方法



考虑  $(f)$      $\text{Min } f(x)$   
其中  $f: \mathbb{R}^n \rightarrow \mathbb{R}$

## 5.1 最优性条件

**定理：**（极小点的一阶必要条件）设  $f$  连续可微，若  $x^*$  是 l.opt.，则  $\nabla f(x^*)=0$ （驻点）。

**定理：**当  $f$  凸时，如果  $x^* \in \mathbb{R}^n$  是驻点（即  $\nabla f(x^*)=0$ ），那么  $x^*$  为  $f$  的最小点。

**注意：**  $f(x) \geq f(x^*) + \nabla f^\top(x^*)(x - x^*)$ ,  $\forall x$

故  $f(x^*) \leq f(x)$ ,  $\forall x$  （由于  $\nabla f^\top(x^*)=0$ ）。



**定理：**（极小点的二阶必要条件）设  $f$  二阶连续可微，若  $x^*$  是 l.opt.，则  $\nabla f(x^*)=0$ ，且海塞矩阵  $\nabla^2 f(x^*)$  半正定。

**定理：**（极小点的二阶充分条件）设  $f$  二阶连续可微， $x^* \in \mathbb{R}^n$  使得  $\nabla f(x^*)=0$ ， $\nabla^2 f(x^*)$  正定，则  $x^*$  为  $f$  的严格 l.opt.。



## 5.2 最速下降法

**方向：**在迭代点  $x^{(k)}$  取方向  $d^{(k)} = -\nabla f(x^{(k)})$

**步长：**精确一维搜索，即求  $\lambda_k$ ，使得

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda \in \mathbb{R}} f(x^{(k)} + \lambda d^{(k)})$$

**更新：** $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$

**最速下降方向：**梯度方向函数值变化最快的方向

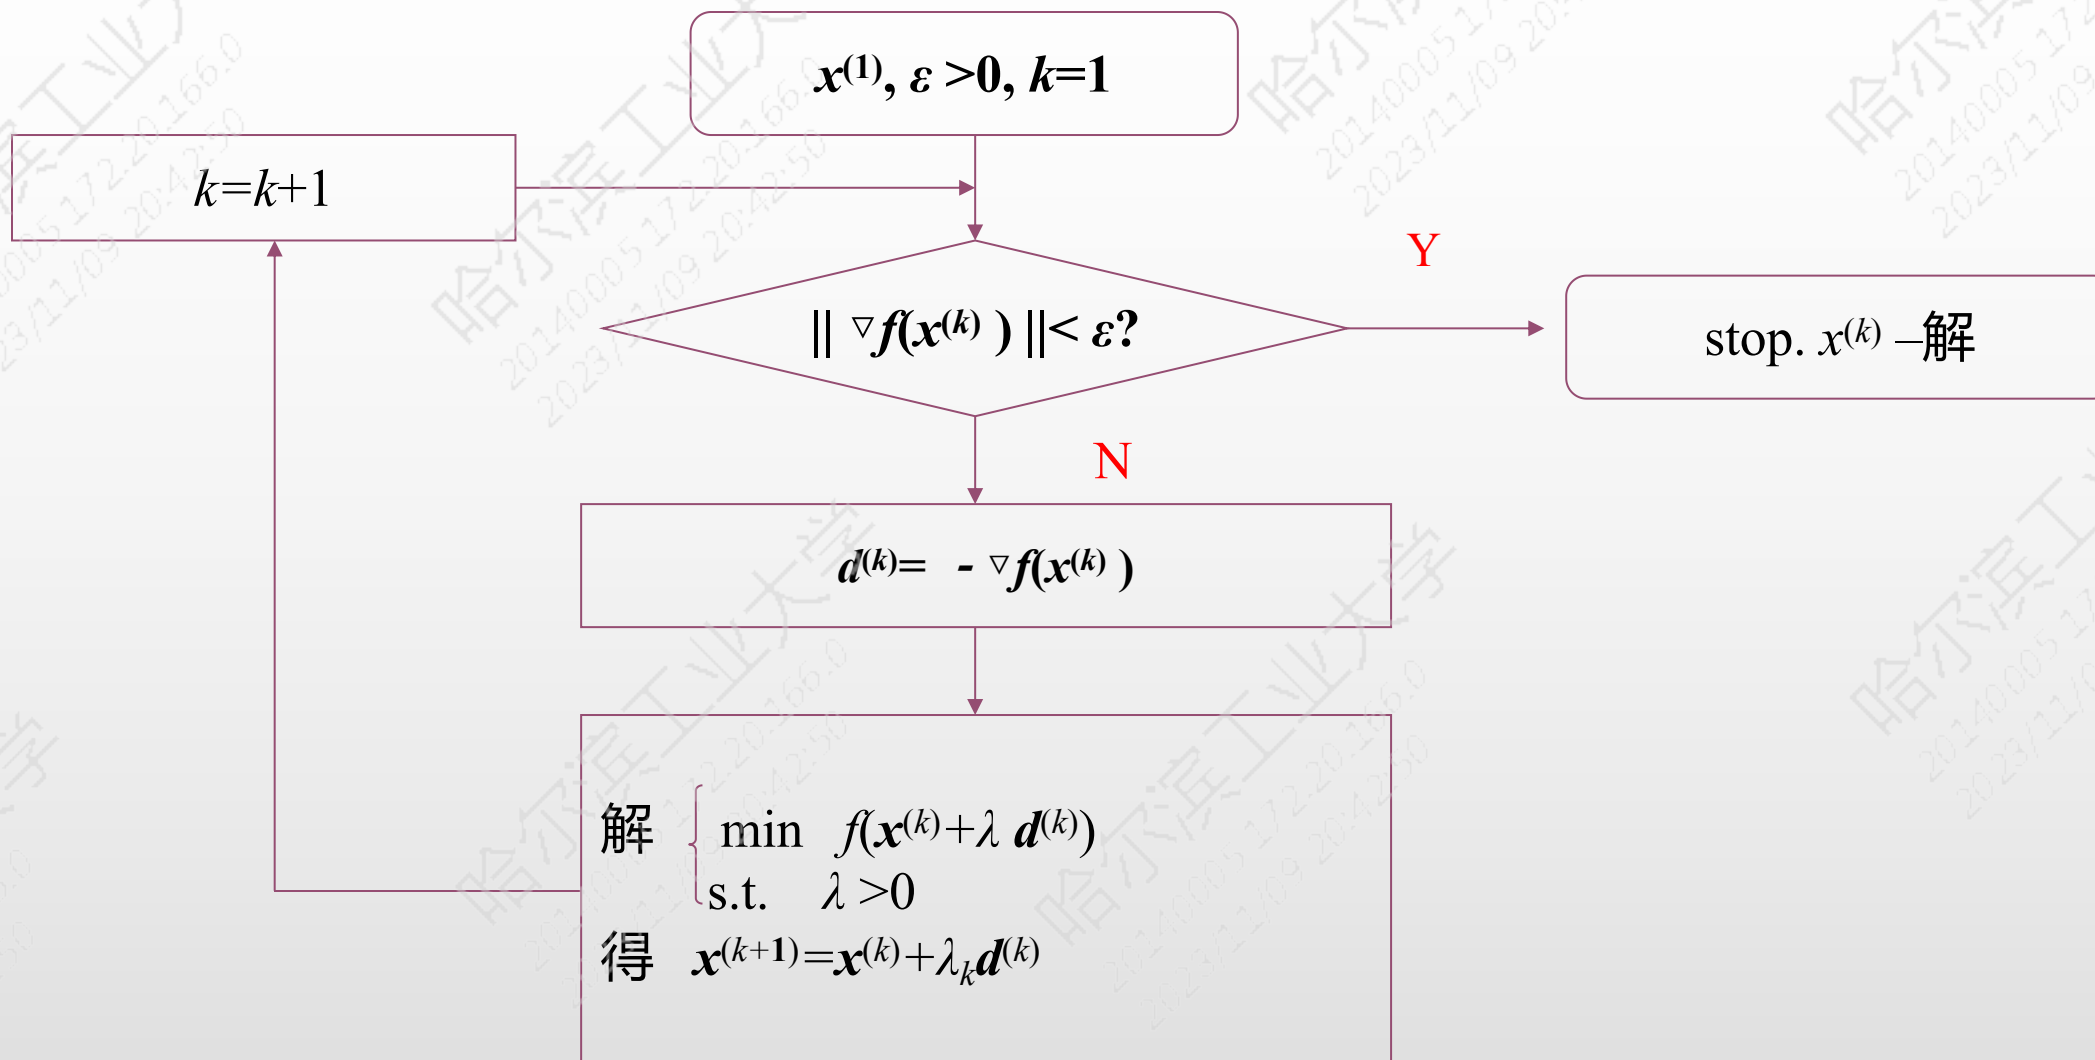
**定理：**设  $f(x): \mathbb{R}^n \rightarrow \mathbb{R}$  在  $x^{(k)}$  处可微， $\nabla f(x^{(k)}) \neq 0$ ，则

$$\begin{cases} \min f'(x^{(k)}; d) \\ \text{s.t. } \|d\| \leq 1, d \in \mathbb{R}^n \end{cases}$$

的最优解是

$$d^{(k)} = -\frac{\nabla f(x^{(k)})}{\|\nabla f(x^{(k)})\|}$$

## 最速下降法的算法流程：





**特点：**全局收敛，线性收敛，易产生扭摆现象（锯齿现象）。  
（当 $x^{(k)}$ 距最优点较远时，速度快，而接近最优点时，速度下降）

**原因：**

用最速下降法极小化目标函数时，相邻两个搜索方向是正交的：

令 $\varphi(\lambda) = f(x^{(k)} + \lambda d^{(k)})$ ，则最小化 $\varphi(\lambda)$ 等价于求

$$\varphi'(\lambda) = \nabla f^T(x^{(k)} + \lambda_k d^{(k)}) d^{(k)} = 0$$

即 $(d^{(k+1)})^T d^{(k)} = 0$ . 这表明迭代产生的序列 $\{x^{(k)}\}$ 所循路径是“之”字形的。当 $x^{(k)}$ 接近l.opt.  $x^*$ 时，每次迭代移动的步长很小，这样就呈现出锯齿现象，因此影响了收敛速率。

## 5.3 共轭梯度法

### 1. 对于正定二次函数

设  $f(x) = (1/2)x^T A x - b^T x$  , 其中  $A_{n \times n}$  对称正定 ,  $b \in \mathbb{R}^n$

**第一步 :** 已知初始点  $x^{(1)}$  , 取最速下降方向

$$d^{(1)} = - \nabla f(x^{(1)}) = b - A x^{(1)} = r^{(1)} \text{ (剩余向量)}$$

接着寻找步长  $\lambda_1$  满足

$$f(x^{(1)} + \lambda_1 d^{(1)}) = \lim_{\lambda \in \mathbb{R}} f(x^{(1)} + \lambda d^{(1)})$$

$$\begin{aligned} \text{由于 } f(x^{(1)} + \lambda d^{(1)}) &= \frac{1}{2} \langle A(x^{(1)} + \lambda d^{(1)}), x^{(1)} + \lambda d^{(1)} \rangle - \langle b, x^{(1)} + \lambda d^{(1)} \rangle \\ &= \frac{1}{2} \langle A x^{(1)}, x^{(1)} \rangle + \lambda \langle A x^{(1)}, d^{(1)} \rangle + \frac{1}{2} \lambda^2 \langle A d^{(1)}, d^{(1)} \rangle - \langle b, x^{(1)} \rangle - \langle b, \lambda d^{(1)} \rangle \\ &= f(x^{(1)}) + \frac{1}{2} \lambda^2 \langle A d^{(1)}, d^{(1)} \rangle - \lambda \langle r^{(1)}, d^{(1)} \rangle \end{aligned}$$

在上式中 , 对  $\lambda$  求导数得  $\lambda_1 = \frac{\langle r^{(1)}, d^{(1)} \rangle}{\langle A d^{(1)}, d^{(1)} \rangle}$

于是得到  $x^{(2)} = x^{(1)} + \lambda_1 d^{(1)}$







**第二步：**已知  $x^{(2)}$ ,  $r^{(2)}$ ,  $d^{(1)}$ , 从  $x^{(2)}$  出发, 取  $d^{(1)}$  的共轭方向  $d^{(2)}$  为下一个搜索方向, 即  $\langle Ad^{(1)}, d^{(2)} \rangle = 0$ .

令  $d^{(2)} = r^{(2)} + \beta d^{(1)}$ , 则  $\langle Ad^{(1)}, d^{(2)} \rangle = \langle Ad^{(1)}, r^{(2)} + \beta d^{(1)} \rangle = 0$ .

于是有  $\beta = -\frac{\langle Ad^{(1)}, r^{(2)} \rangle}{\langle Ad^{(1)}, d^{(1)} \rangle}$ .

再求  $\lambda_2$  使得

$$f(x^{(2)} + \lambda_2 d^{(2)}) = \lim_{\lambda \in \mathbb{R}} f(x^{(2)} + \lambda d^{(2)})$$

于是有  $\lambda_2 = \frac{\langle r^{(2)}, d^{(2)} \rangle}{\langle Ad^{(2)}, d^{(2)} \rangle}$ , 从而  $x^{(3)} = x^{(2)} + \lambda_2 d^{(2)}$

**第三步：**重复第二步



**例.** 用共轭梯度法求解  $10x_1^2 + x_2^2$  的最小值

**解：** 取初始点  $x^{(1)} = (1/10, 1)^T$

得到如下结果：

$k$	$x^{(k)}$	$\nabla f(x^{(k)})$	$\beta_{k-1}$	$d^{(k)}$	$\lambda_k$
1	$\left(\frac{1}{10}, 1\right)^T$	$(2, 2)^T$	0	$(-2, -2)^T$	$\frac{1}{11}$
2	$\left(-\frac{9}{110}, \frac{9}{11}\right)^T$	$\left(-\frac{18}{11}, \frac{18}{11}\right)^T$	$\frac{81}{121}$	$\left(\frac{36}{121}, -\frac{360}{121}\right)^T$	$\frac{11}{40}$
3	$(0, 0)^T$	$(0, 0)^T$			



### 定理：

(1) 剩余向量组构成一个正交向量组，即

$$\langle r^{(i)}, r^{(j)} \rangle = 0, \text{ 当 } i \neq j$$

(2)  $\{d^{(k)}\}$  构成一个A共轭向量组，即

$$\langle d^{(i)}, Ad^{(j)} \rangle = 0, \text{ 当 } i \neq j$$

(3)  $\langle r^{(i)}, r^{(i)} \rangle = \langle r^{(i)}, d^{(i)} \rangle$

### 共轭方向的例子：二维

(1) 任选初始点  $x^{(0)}$

(2) 最速下降方向  $d^{(0)}$

(3) 得到  $x^{(1)} = x^{(0)} + \lambda_0 d^{(0)}$

(4) 共轭方向  $d^{(1)}$

(5) 得到  $x^* = x^{(2)} = x^{(1)} + \lambda_1 d^{(1)}$

为最优解

### 原因：

$$Ax^* - b$$

$$= A(x^{(1)} + \lambda_1 d^{(1)}) - b$$

$$= Ax^{(1)} - b + \lambda_1 Ad^{(1)}$$

$$= \nabla f(x^{(1)}) + \lambda_1 Ad^{(1)}$$

$$\text{计算 } \langle Ax^* - b, d^{(0)} \rangle = 0,$$

即  $Ax^* - b$  与  $d^{(0)}$  垂直。

由  $x^{(0)}$  的任意性，故  $d^{(0)}$  也是任意的，进而  $Ax^* - b = 0$



## 2.对于一般的函数的共轭梯度法

共轭方向为：

$$d^{(k+1)} = -\nabla f(x^{(k+1)}) + \beta_k d^{(k)}$$

其中 $\beta_k$ 有以下的选择方式：

$$\beta_k = \frac{\nabla f(x^{(k+1)})^T \nabla f(x^{(k+1)})}{\nabla f(x^{(k)})^T \nabla f(x^{(k)})} \quad FR去$$

$$\beta_k = \frac{\nabla f(x^{(k+1)})^T [\nabla f(x^{(k+1)}) - \nabla f(x^{(k)})]}{\nabla f(x^{(k)})^T \nabla f(x^{(k)})} \quad PR去$$

$$\beta_k = \frac{\nabla f(x^{(k+1)})^T \nabla f(x^{(k+1)})}{-\nabla f(x^{(k)})^T d^{(k)}} \quad \text{共轭下降法}$$

**注：**这些表达式在二次函数情况下是等价的。



## 算法特点

(1) 全局收敛（下降算法），线性收敛。

共轭梯度方向为下降方向：

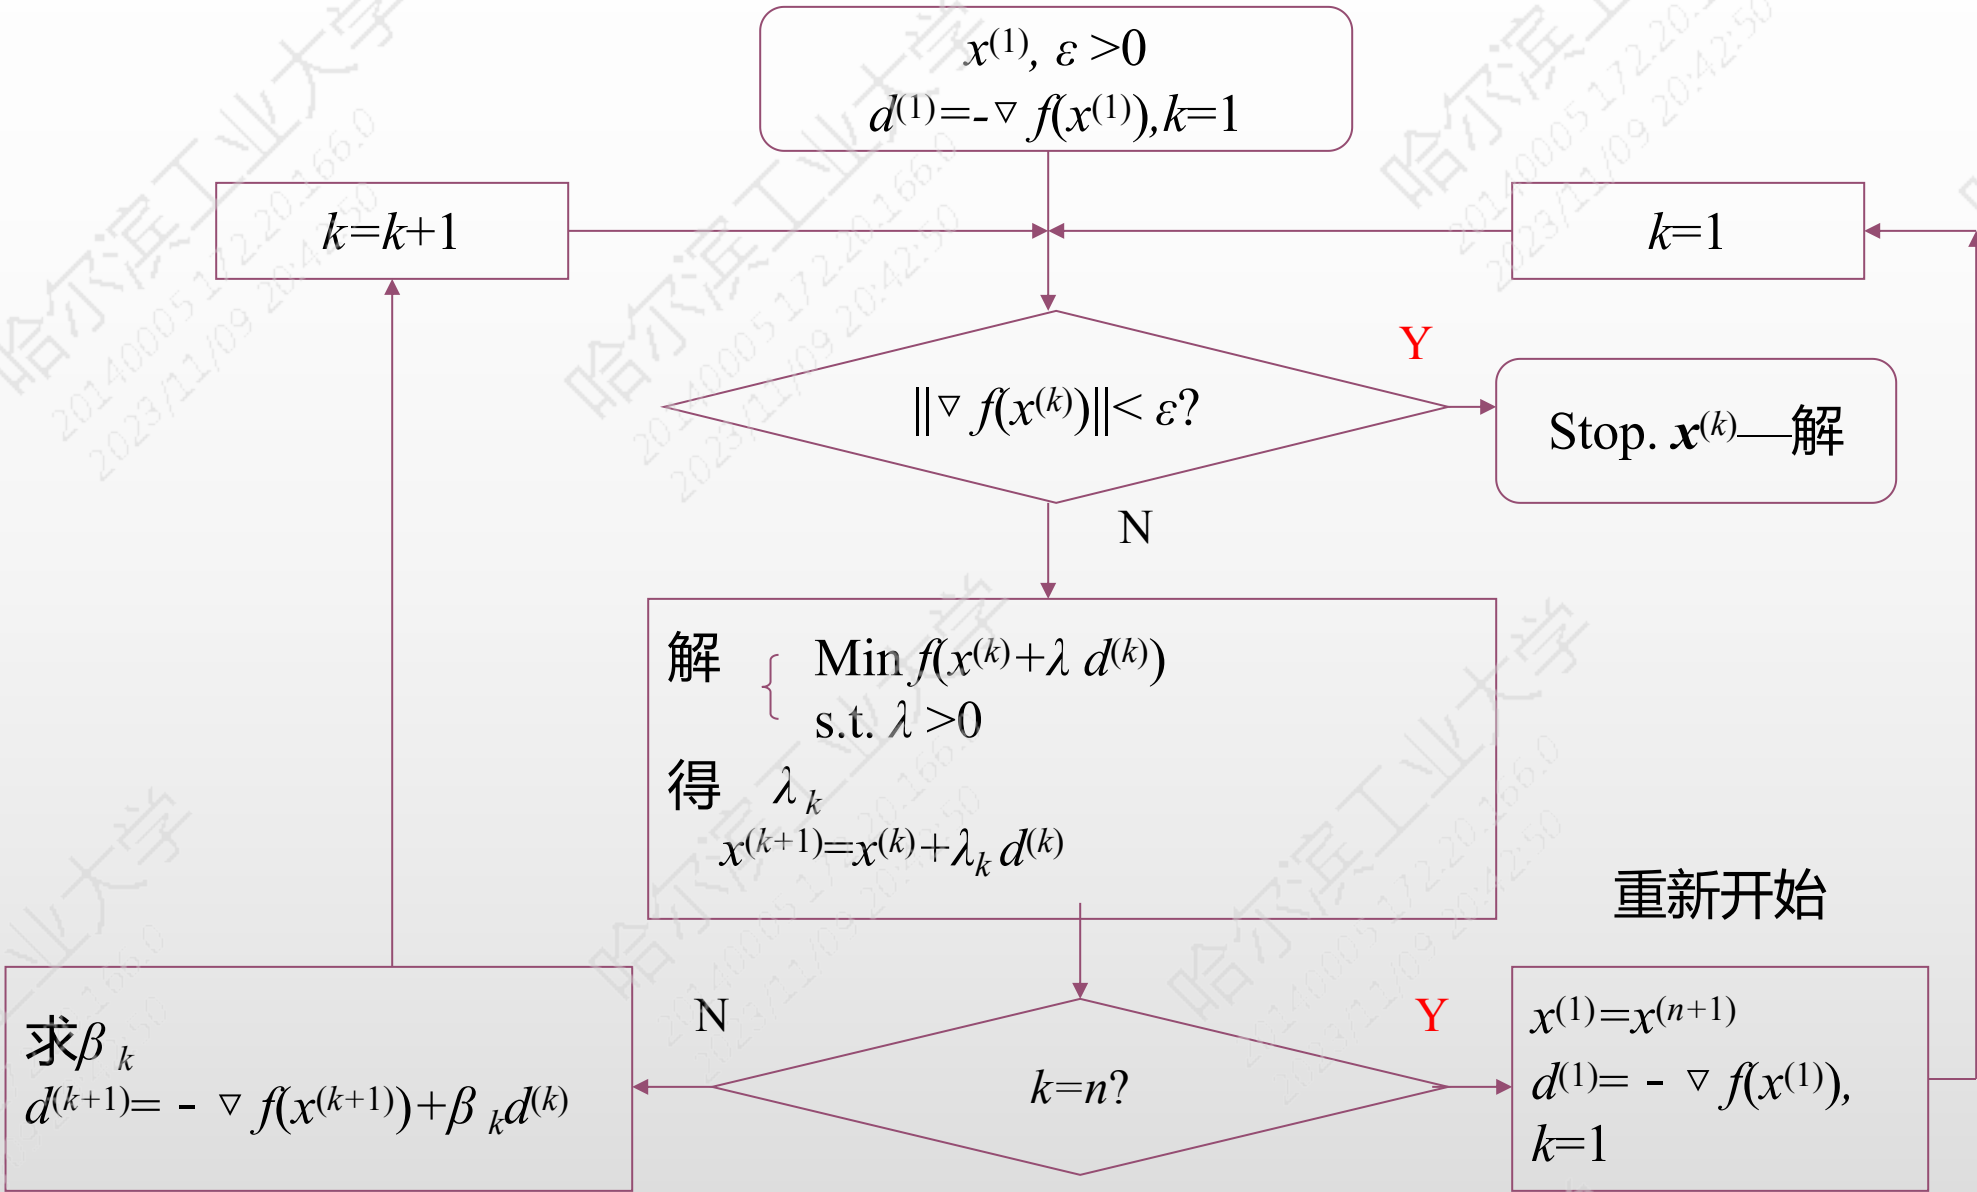
$$\begin{aligned} & \nabla f^T(x^{(k)})d^{(k)} \\ &= \nabla f^T(x^{(k)})(-\nabla f(x^{(k)}) + \beta_{k-1}d^{(k-1)}) \\ &= -\nabla f^T(x^{(k)})\nabla f(x^{(k)}) < 0 \end{aligned}$$

(2) 每步迭代只需存储若干向量（适用于大规模问题）。

(3) 有二次终结性（对于正定二次函数，至多 $n$ 次迭代可达opt.）。

注：对不同的 $\beta_k$ 公式，对于正定二次函数是相等的，对非正定二次函数，有不同的效果，经验上PRP效果较好。

# 共轭梯度法算法流程图





## 5.4 牛顿法及其修正

### 1. 牛顿法

设  $f \in C^2(\mathbb{R}^n)$  , 又设已得到迭代点  $x^{(k)}$  , 将  $f(x^{(k)} + s)$  在  $x^{(k)}$  处作Taylor展开得到

$$f(x^{(k)} + s) = f(x^{(k)}) + \nabla^T f(x^{(k)})s + 1/2s^T \nabla^2 f(x^{(k)})s + o(\|s\|^2)$$

令  $s = x - x^{(k)}$  , 并取  $q_k(x)$  为

$$q_k(x) = f(x^{(k)}) + \nabla^T f(x^{(k)})s + 1/2s^T \nabla^2 f(x^{(k)})s$$

则  $q_k(x)$  是  $f(x)$  在  $x^{(k)}$  附近的一个二阶近似。

设  $\nabla^2 f(x^{(k)})$  正定 , 则  $q_k(x)$  有唯一的驻点 , 即  $\nabla q_k(x) = 0$  .

由此得到(牛顿方向)

$$s^{(k)} = - [\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)})$$

因此

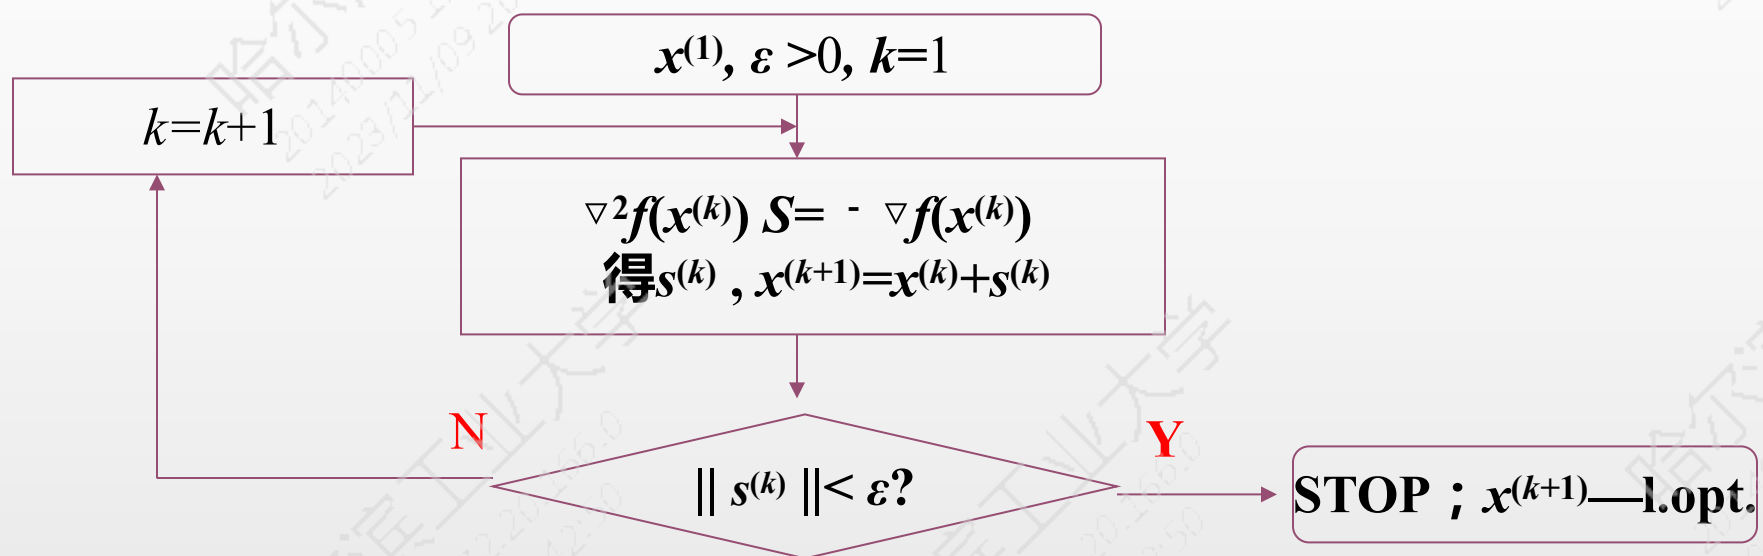
$$x^{(k+1)} = x^{(k)} + s^{(k)}$$

通常  $s^{(k)}$  是通过求解线性方程组 ( 牛顿方程 ) 得到的

$$\nabla^2 f(x^{(k)})s^{(k)} = - \nabla f(x^{(k)})$$



## 牛顿法的算法流程图：







**优点：**

**(1) 二阶收敛**

( 当 $x^{(k)}$ 充分接近 $x^*$ 时,局部函数可用正定二次函数很好地近似 , 故收敛很快 )

**(2) 二次终结性：当 $f(x)$ 为正定二次函数时 , 从任意初始点可一步迭代达到最优解**

设 $f(x) = (1/2) x^T Q x + P^T x + r$  ,  $Q_{n \times n}$  对称正定 ,  $P \in R^n$  ,  $r \in R$ 。  $\forall x^{(1)}$ ,

$$\nabla f(x^{(1)}) = Q x^{(1)} + P , \quad \nabla^2 f(x^{(1)}) = Q$$

迭代：  $x^{(2)} = x^{(1)} - Q^{-1}(Q x^{(1)} + P) = - Q^{-1} P$  (驻点即opt.)



## 主要缺点：

(1)局部收敛

(2)用到二阶Hesse矩阵，且要求正定

(3)需计算Hesse矩阵逆或解 $n$ 阶线性方程组，计算量大

(4)需要 $f \in C^2$



## 2. 修正的牛顿算法

### (1) 减少计算量的直接求法

为减小工作量，取 $m$ （正整数），使每 $m$ 次迭代使用同一个Hesse矩阵，迭代公式变为

$$\mathbf{x}^{(km+j+1)} = \mathbf{x}^{(km+j)} - [\nabla^2 f(\mathbf{x}^{(km)})]^{-1} \nabla f(\mathbf{x}^{(km+j)})$$

$$j=0,1,2, \dots, m-1, \quad k=0,1,2, \dots$$

特点：收敛速度随 $m$ 的增大而下降。

此方法的收敛阶数为 $p = (m+1)^{1/m} \leq 2$

当 $m=1$ 时即Newton法，收敛阶数 $p=2$

当 $m \rightarrow \infty$ 时即线性收敛。收敛阶数 $p=1$ （因为 $\lim_{m \rightarrow \infty} \ln(m+1)^{1/m} = 0$ ）



(2)带线性搜索的Newton法(阻尼牛顿法, 阻尼因子 $\lambda_k$ ):

在Newton迭代中, 取 $d^{(k)} = -[\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)})$ , 加入线性搜索:

$$\min f(x^{(k)} + \lambda_k d^{(k)})$$

求得  $\lambda_k$ ,  $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$

特点: 可改善局部收敛性, 当 $d^{(k)}$ 为函数上升方向时, 可向负方向搜索, 但可能出现 $\pm d^{(k)}$ 均非下降方向的情况。



### (3) Goldstein-Price方法(G-P法)

取  $d^{(k)} = \begin{cases} - [\nabla^2 f(x^{(k)})]^{-1} \nabla f(x^{(k)}) & , \nabla^2 f(x^{(k)}) \text{ 正定} \\ - \nabla f(x^{(k)}) & , \text{ 否则} \end{cases}$

采用下列不精确一维搜索：求  $\lambda_k$ ，使其中  $\delta \in (0, 1/2)$

$$1^\circ f(x^{(k)} + \lambda_k d^{(k)}) \leq f(x^{(k)}) + \delta \nabla f^\top(x^{(k)}) d^{(k)} \lambda_k$$

$$2^\circ f(x^{(k)} + \lambda_k d^{(k)}) \geq f(x^{(k)}) + (1 - \delta) \nabla f^\top(x^{(k)}) d^{(k)} \lambda_k$$

特点：在一定条件下，G-P法全局收敛。

但当  $\nabla^2 f(x^{(k)})$  非正定情况较多时，收敛速度降为接近线性。



## (4) Levenberg-Marguardt法 ( L-M法 ) ( 强迫Hesse矩阵正定 )

主要思想：

用  $[\nabla^2 f(\mathbf{x}^{(k)}) + \mu E]$  取代  $\nabla^2 f(\mathbf{x}^{(k)})$  进行迭代，  
其中  $E$  为单位矩阵。  $\mu > 0$  使  $[\nabla^2 f(\mathbf{x}^{(k)}) + \mu E]$  正定，  
 $\mu$  尽量小。

特点：全局二阶收敛。



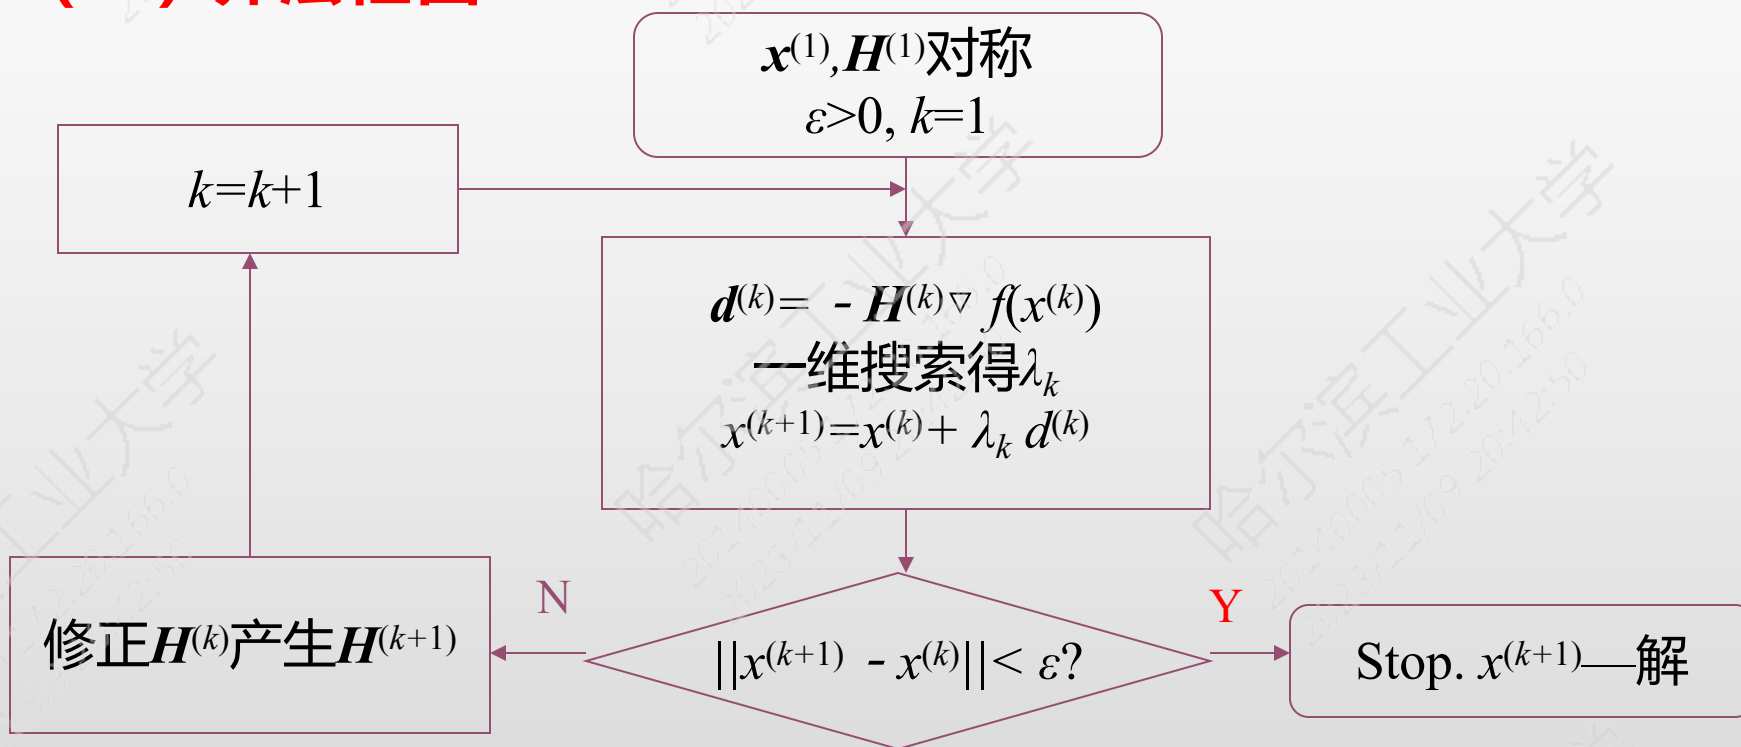
## 5.5 变尺度法

1. 变尺度法的基本思路：  $(f) \text{Min } f(x), \quad f: \mathbb{R}^n \rightarrow \mathbb{R}$

### (1) 基本思想

用对称正定矩阵  $H^{(k)}$  近似  $(\nabla^2 f(x^{(k)}))^{-1}$ ，而  $H^{(k)}$  的产生是从给定  $H^{(1)}$  开始逐步修正得到。

### (2) 算法框图





### (3) 拟Newton方程

记  $s^{(k)} = x^{(k+1)} - x^{(k)}$ ,  $y^{(k)} = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$

当  $f$  为二次函数时:  $f(x) = (1/2)x^T Bx + c^T x + b$

$$\nabla f = Bx + c$$

有  $y^{(k)} = Bs^{(k)}$  或  $s^{(k)} = B^{-1} y^{(k)}$

称  $Hy = S$  或  $y = BS$  为拟Newton方程。

显然, 当  $H$  正定时,  $B^{-1} = H$ .

(4) “近似”  $x^{(k+2)} = x^{(k+1)} + \lambda_{k+1} d^{(k+1)}$ , 其中  $d^{(k+1)} = -(\nabla^2 f(x^{(k+1)}))^{-1} \nabla f(x^{(k+1)})$

问题: 如何找  $\nabla^2 f(x^{(k+1)})$  或  $(\nabla^2 f(x^{(k+1)}))^{-1}$  的近似?

对于  $\nabla f(x)$  作Taylor展式, 舍去高阶项有

$$\nabla f(x^{(k)}) \approx \nabla f(x^{(k+1)}) + \nabla^2 f(x^{(k+1)}) (x^{(k)} - x^{(k+1)})$$

即  $y^{(k)} \approx \nabla^2 f(x^{(k+1)}) s^{(k)}$  或  $s^{(k)} \approx (\nabla^2 f(x^{(k+1)}))^{-1} y^{(k)}$

用矩阵  $B^{(k+1)}$  或  $H^{(k+1)}$  分别取代  $\nabla^2 f(x^{(k+1)})$  或者  $(\nabla^2 f(x^{(k+1)}))^{-1}$  使拟Newton方程成立。

$B^{(k+1)}$  或  $H^{(k+1)}$  可看做是对  $\nabla^2 f(x^{(k+1)})$  或  $(\nabla^2 f(x^{(k+1)}))^{-1}$  的一种近似。

此种近似  $H$  或  $B$  不唯一。





## **( 5 ) 变尺度法的主要特点**

- 1 ) 只需用到函数的一阶梯度 ( Newton法用到二阶Hesse矩阵 ) ;**
- 2 ) 下降算法 , 故全局收敛 ;**
- 3 ) 不需求矩阵逆 ( 计算量小 ) ;**
- 4 ) 一般可达到超线性收敛 ( 速度快 ) ;**
- 5 ) 有二次终结性。**



## 2.DFP ( Davidon(1959),Fletcher and Powell(1963) ) 法和 BFGS ( Broyden(1970), Fletcher (1970),Goldfarb(1970),Schanno(1970) ) 法 ( 1 ) DFP法

以下省去各量上标 ,  $x, s, y, H$  表示第 $k$  步的量 ,  $\bar{x}, \bar{s}, \bar{y}, \bar{H}$   
等表示第 $k+1$ 步的量。

令修正公式为  $\bar{H} = H + \alpha uu^T + \beta vv^T, u, v \in \mathbb{R}^n$

代入拟Newton条件  $s = \bar{H}y$  有

$$s = (H + \alpha uu^T + \beta vv^T)y = Hy + \alpha(u^T y)u + \beta(v^T y)v$$

取 :  $u = s, v = Hy$

则有  $\alpha = \frac{1}{s^T y}, \beta = -\frac{1}{y^T Hy}$

DFP公式 :  $\bar{H} = H + \frac{ss^T}{s^T y} - \frac{Hyy^T H}{y^T Hy}$



例. 用DFP法求解  $10x_1^2 + x_2^2$

解：取初始点  $x^{(1)} = (1/10, 1)^T$ ,  $H^{(1)} = E$  (单位矩阵)

得到如下结果：（计算过程见下页）

$$\nabla f(x) = \begin{pmatrix} 20x_1 \\ 2x_2 \end{pmatrix}, \quad d = -H\nabla f(x) \quad s = \bar{x} - x = \lambda d$$

$k$	$x^{(k)}$	$\nabla f(x^{(k)})$	$H^{(k)}$	$d^{(k)}$	$\lambda_k$	$S^{(k)}$	$y^{(k)}$
1	$\begin{pmatrix} \frac{1}{10} \\ 1 \end{pmatrix}$	$\begin{pmatrix} 2 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$	$\begin{pmatrix} -2 \\ -2 \end{pmatrix}$	$\frac{1}{11}$	$\begin{pmatrix} -\frac{2}{11} \\ -\frac{2}{11} \end{pmatrix}$	$\begin{pmatrix} -\frac{40}{11} \\ -\frac{4}{11} \end{pmatrix}$
2	$\begin{pmatrix} -\frac{9}{110} \\ \frac{9}{11} \end{pmatrix}$	$\begin{pmatrix} -\frac{18}{11} \\ \frac{18}{11} \end{pmatrix}$	$\frac{1}{2222} \begin{pmatrix} 123 & -119 \\ -119 & 2301 \end{pmatrix}$	$\begin{pmatrix} 1 \\ -10 \end{pmatrix}$	$\frac{9}{110}$		
3	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	停				



## 计算过程

第一步:

$$d^{(1)} = -H^{(1)} \nabla f(x^{(1)}) = -\begin{pmatrix} 2 \\ 2 \end{pmatrix} \quad x^{(1)} + \lambda d^{(1)} = \begin{pmatrix} \frac{1}{10} - 2\lambda \\ 1 - 2\lambda \end{pmatrix}$$

一维搜索: 
$$\begin{cases} \min f(x^{(1)} + \lambda d^{(1)}) = 10\left(\frac{1}{10} - 2\lambda\right)^2 + (1 - 2\lambda)^2 \\ s.t. \quad \lambda \geq 0 \end{cases}$$

求  $f(x^{(1)} + \lambda d^{(1)})$  的驻点:

$$f' = -40\left(\frac{1}{10} - 2\lambda\right) - 4(1 - 2\lambda) = 0 \quad \text{得 } \lambda = \frac{1}{11}$$

于是 
$$x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \left(-\frac{9}{110}, \frac{9}{11}\right)^T$$

第二步:

$$\nabla f(x^{(2)}) = \left(-\frac{18}{11}, \frac{18}{11}\right)^T \quad s^{(1)} = x^{(2)} - x^{(1)} = \left(-\frac{2}{11}, -\frac{2}{11}\right)^T$$

$$y^{(1)} = \nabla f(x^{(2)}) - \nabla f(x^{(1)}) = \left(-\frac{40}{11}, -\frac{4}{11}\right)^T$$



$$H^{(2)} = H^{(1)} + \frac{s^{(1)} s^{(1)T}}{s^{(1)T} y^{(1)}} - \frac{H^{(1)} y^{(1)} y^{(1)T} H^{(1)}}{y^{(1)T} H^{(1)} y^{(1)}}$$

$$s^{(1)T} y^{(1)} = \frac{8}{11} \quad H^{(1)} y^{(1)} = y^{(1)} \quad y^{(1)T} H^{(1)} y^{(1)} = \frac{1616}{121}$$

$$s^{(1)} s^{(1)T} = \begin{pmatrix} \frac{4}{121} & \frac{4}{121} \\ \frac{4}{121} & \frac{4}{121} \end{pmatrix} \quad H^{(1)} y^{(1)} y^{(1)T} H^{(1)} = \begin{pmatrix} \frac{1600}{121} & \frac{160}{121} \\ \frac{160}{121} & \frac{16}{121} \end{pmatrix}$$

$$\text{于是: } H^{(2)} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \frac{1}{22} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} - \frac{1}{101} \begin{pmatrix} 100 & 10 \\ 10 & 1 \end{pmatrix} = \frac{1}{2222} \begin{pmatrix} 123 & -119 \\ -119 & 2301 \end{pmatrix}$$

$$d^{(2)} = -H^{(2)} \nabla f(x^{(2)}) = \frac{4356}{2222} \begin{pmatrix} 1 \\ -10 \end{pmatrix} \quad \text{取 } d^{(2)} = \begin{pmatrix} 1 \\ -10 \end{pmatrix} \quad (\text{与长度无关})$$

$$\min f(x^{(2)} + \lambda d^{(2)}) = 10 \left(-\frac{9}{110} + \lambda\right)^2 + \left(\frac{9}{11} - 10\lambda\right)^2 \quad \text{求驻点: } \lambda_2 = \frac{9}{110}$$

$$x^{(3)} = x^{(2)} + \lambda_2 d^{(2)} = (0, 0)^T$$

$$\text{第三步: } \nabla f(x^{(3)}) = (0, 0)^T \quad \text{停。} \quad x^* = (0, 0)^T$$



**定理：**设 $H$ 对称正定， $s^T y > 0$ 那么DFP法产生的 $\bar{H}$ 对称正定。

**注：**下列各情况下有 $s^T y > 0$ ：

- 1°  $f(x)$ 为正定二次函数；
- 2° 精确一维搜索时；
- 3° 前章介绍的不精确一维搜索时。

**可以证明：**DFP法在精确一维搜索前提下，超线性收敛。



## (2) BFGS法

若把前面的推导平行地用在 $y=Bs$ 公式上，可得到

$$\bar{B} = B + \frac{yy^T}{y^T s} - \frac{Bss^T B}{s^T Bs} \quad \text{——BFGS的} B \text{公式}$$

用此公式求方向时，需用到矩阵求逆或解方程：

$$d = -B^{-1} \nabla f(x) \quad \text{或} \quad Bd = -\nabla f(x)$$

由于每次只有秩2的变换，这里的计算量仍可以降下来（但相对于H-公式还是高一些）。

为了得到H-公式，可对上面 $\bar{B}$ 求逆

$$\left( \text{利用求逆公式 } (M + uv^T)^{-1} = M^{-1} - \frac{M^{-1}uv^T M^{-1}}{1 + v^T M^{-1}u} \right) :$$

$$\bar{H} = H + \left(1 + \frac{y^T Hy}{s^T y}\right) \frac{ss^T}{s^T y} - \frac{Hys^T + sy^T H}{s^T y} \quad \text{——BFGS的} H \text{公式}$$

BFGS法有变尺度法的全部优点，并且在一定条件下可以证明在BFGS法中使用前文中介绍的不精确一维搜索有全局收敛性。



例. 用BFGS法求解  $10x_1^2+x_2^2$

解：取初始点  $x^{(1)}=(1/10,1)^T$ ,  $H^{(1)}=E$  (单位矩阵)

得到如下结果：

$$\nabla f(x)=\begin{pmatrix} 20x_1 \\ 2x_2 \end{pmatrix}, \quad d=-H\nabla f(x) \quad S=\bar{x}-x=\lambda d$$

$k$	$x^{(k)}$	$\nabla f(x^{(k)})$	$H^{(k)}$	$d^{(k)}$	$\lambda_k$	$s^{(k)}$	$y^{(k)}$
1	$\begin{pmatrix} 1/10 \\ 1 \end{pmatrix}$	$\begin{pmatrix} 2 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$	$\begin{pmatrix} -2 \\ -2 \end{pmatrix}$	$\frac{1}{11}$	$\begin{pmatrix} -\frac{2}{11} \\ -\frac{2}{11} \end{pmatrix}$	$\begin{pmatrix} -\frac{40}{11} \\ \frac{4}{11} \end{pmatrix}$
2	$\begin{pmatrix} -\frac{9}{110} \\ \frac{9}{11} \end{pmatrix}$	$\begin{pmatrix} -\frac{18}{11} \\ \frac{18}{11} \end{pmatrix}$	$\frac{1}{242}\begin{pmatrix} 15 & -29 \\ -29 & 411 \end{pmatrix}$	$\frac{36}{121}\begin{pmatrix} 1 \\ -10 \end{pmatrix}$	$\frac{11}{40}$	$\begin{pmatrix} \frac{9}{110} \\ -\frac{9}{11} \end{pmatrix}$	$\begin{pmatrix} \frac{18}{11} \\ -\frac{18}{11} \end{pmatrix}$
3	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$					





### 3. Broyden族

当在秩2公式中， $\alpha$ 、 $\beta$  任意选取时可得到不同的公式，经过理论推导，可得到下列结果：

(1) DFP 的  $B$  公式：
$$\bar{B} = B + \left(1 + \frac{s^T B s}{s^T y}\right) \frac{y y^T}{s^T y} - \frac{B s y^T + y s^T B}{s^T y}$$

DFP 公式与 BFGS 公式，通过用  $s, y, H(B)$  分别取代  $y, s, B(H)$

即可互相得到，称它们 为对偶公式。

(2) 令 DFP 法，BFGS 法的  $H$  公式分别为  $\bar{H}_{DFP}, \bar{H}_{BFGS}$ ，引入参数  $\Phi$

(一般取  $0 \leq \Phi \leq 1$ ) 有下列公式：

1° 
$$\bar{H}_{\Phi} = (1 - \Phi) \bar{H}_{DFP} + \Phi \bar{H}_{BFGS}$$

2° 
$$\bar{H}_{\Phi} = \bar{H}_{DFP} + \Phi v v^T$$



其中:  $v = (y^T Hy)^{\frac{1}{2}} \left( \frac{s}{s^T y} - \frac{Hy}{y^T Hy} \right)$

3°  $\bar{H}_{\Phi} = \bar{H}_{DFP} + (s, Hy) A_{\Phi} \begin{pmatrix} s^T \\ Hy^T \end{pmatrix}$

其中:  $A_{\Phi} = \begin{pmatrix} (1 + \Phi \frac{y^T Hy}{s^T y}) \frac{1}{s^T y} & -\frac{\Phi}{s^T y} \\ -\frac{\Phi}{s^T y} & -\frac{1 - \Phi}{y^T Hy} \end{pmatrix}_{2 \times 2}$

上述公式均是等价的, 称为 *Broyden* 族。

显然当  $\Phi = 0$  时即 *DFP* 公式;

当  $\Phi = 1$  时即 *BFGS* 公式。

*Broyden* 族的任何公式都具备一般变尺度法的优点。

## 5.6 直接算法



Min  $f(x)$

### 1. 单纯形法及可变多面体算法

#### (1) 单纯形法基本思路

设  $x^{(0)}, x^{(1)}, \dots, x^{(n)}$  是  $R^n$  中  $n+1$  个点构成的一个当前的单纯形。

比较各点的函数值得到： $x_{\max}, x_{\min}$  使

$$f(x_{\max}) = \max\{f(x^{(0)}), f(x^{(1)}), \dots, f(x^{(n)})\}$$

$$f(x_{\min}) = \min\{f(x^{(0)}), f(x^{(1)}), \dots, f(x^{(n)})\}$$

取单纯形中除去  $x_{\max}$  点外，其他各点的形心

$$\bar{x} = \frac{1}{n} \left( \sum_{i=0}^n x^{(i)} - x_{\max} \right)$$

取  $x^{(n+1)}$  为  $x_{\max}$  关于  $\bar{x}$  的反射点： $x^{(n+1)} = \bar{x} + (\bar{x} - x_{\max})$

去掉  $x_{\max}$ ，加入  $x^{(n+1)}$  得到新的单纯形。

重复上述过程。


## 几点注意：

- (1) 当  $x^{(n+1)}$  又是新单纯形的最大值点时，取次大值点进行反射；
- (2) 若某一个点  $x'$  出现在连续  $m$  个单纯形中的时候，取各点与  $x'$  连线的中点（ $n$  个）与  $x'$  点构成新的单纯形，继续进行。

经验上取  $m \geq 1.65n + 0.05n^2$

例如： $n=2$  时，可取  $m \geq 1.65 \times 2 + 0.05 \times 4 = 3.5$

可取  $m=4$ 。





优点：不要求导数，不需要一维搜索。

缺点：无法加速，收敛慢，效果差。

## (2) 改进单纯形法 (可变多面体算法)

设第 $k$ 步迭代得到 $n+1$ 个点： $x^{(0)}, x^{(1)}, \dots, x^{(n)}$ ，得到 $x_{\max}$ ， $x_{\min}$ 及

通过下列4步操作选新迭代点：

1° 反射：取反射系数 $\alpha > 0$  (单纯形法中 $\alpha = 1$ )

$$y^{(1)} = \bar{x} + \alpha(\bar{x} - x_{\max})$$

2° 扩展：给定扩展系数 $\gamma > 1$ , 计算 (加速)

$$y^{(2)} = \bar{x} + \gamma(y^{(1)} - \bar{x})$$

若 $f(y^{(1)}) < f(x_{\min})$ ，则若 $f(y^{(1)}) > f(y^{(2)})$ ，那么 $y^{(2)}$ 取代 $x_{\max}$ ；否则， $y^{(1)}$ 取代 $x_{\max}$

若 $\max\{f(x^{(i)}) \mid x^{(i)} \neq x_{\max}\} \geq f(y^{(1)}) \geq f(x_{\min})$ ， $y^{(1)}$ 取代 $x_{\max}$



3° 收缩：若 $f(x_{\max}) > f(y^{(1)}) > f(x^{(i)})$ ,  $x^{(i)} \neq x_{\max}$ , 计算

$$y^{(3)} = \bar{x} + \beta(y^{(1)} - \bar{x}) \quad \beta \in (0,1)$$

以 $y^{(3)}$ 取代 $x_{\max}$ 。

4° 减半：若 $f(y^{(1)}) > f(x_{\max})$ , 重新取各点, 使 $x^{(i)} = x_{\min} + 1/2(x^{(i)} - x_{\min})$  得到新单纯形。

经验上： $\alpha=1, 0.4 \leq \beta \leq 0.6, 2.3 \leq \gamma \leq 3.0$

有人建议： $\alpha=1, \beta=0.5, \gamma=2$

算法停机准则取：

$$\frac{1}{n+1} \sum_{i=0}^n [f(x^{(i)}) - f(x_{\min})]^2 < \varepsilon$$



## 2. 模式搜索法：Hooke & Jeeves (1961)

### (1) 基本思想与主要过程

- 利用两类移动（探测性移动和模式性移动）进行一步迭代：

探测性移动的目的：探求一个沿各坐标方向的新点并得到一个“有前途”的方向；

模式性移动的目的：沿上述“有前途”方向加速移动。

- 主要过程：第 $k$ 步迭代，设已得到 $x^{(k)}$

1° 探测性移动：

给定步长 $\alpha_k$ ，设通过模式性移动得到 $y^{(0)}$ ，

依次沿各坐标方向 $e^{(i)} = (0, \dots, 1, 0, \dots, 0)^T$   
 $i$

移动 $\alpha_k$ 步长： $i=0, 1, \dots, n-1$ ， $\bar{y} = y^{(i)} + \alpha_k e^{(i+1)}$

若 $f(\bar{y}) < f(y^{(i)})$ ，则  $y^{(i+1)} = \bar{y}$





否则取  $\bar{y} = y^{(i)} - \alpha_k e^{(i+1)}$

若  $f(\bar{y}) < f(y^{(i)})$ , 则  $y^{(i+1)} = \bar{y}$

否则  $y^{(i+1)} = y^{(i)}$

最后得到  $y^{(n)}$ 。

若  $f(y^{(n)}) < f(x^{(k)})$ , 令  $x^{(k+1)} = y^{(n)}$ 。

### 2° 模式性移动

$x^{(k+1)} - x^{(k)}$  为一个有前途的方向, 取

$$y^{(0)} = x^{(k+1)} + (x^{(k+1)} - x^{(k)}) = 2x^{(k+1)} - x^{(k)}$$

[但不一定保证  $f(y^{(0)}) < f(x^{(k+1)})$ ]

### 3° 几点措施:


① 若探测性移动得到  $y^{(n)}$  使  $f(y^{(n)}) \geq f(x^{(k)})$ , 则跳过模式性移动而令  $y^{(0)} = x^{(k)}$  重新进行探测性移动

② 若  $y^{(n)} = y^{(0)}$  (即每一个坐标方向的移动都失败), 减小  $\alpha_k$ , 重复上述过程。

③ 当进行到  $\alpha_k$  充分小 ( $\alpha_k < \varepsilon$ ) 时, 终止计算。最新的迭代点  $x^{(k)}$  为解。



例：



## (2) 算法：

